

ỨNG DỤNG PHƯƠNG PHÁP CẢI THIÊN KẾT QUẢ PHÂN CỤM DỮ LIỆU CÁC CỬA HÀNG TRÊN SÀN THƯƠNG MẠI ĐIỆN TỬ TIKI

Ứng dụng kết hợp khai thác tập mục thường xuyên và phân cụm

Nguyễn Văn Đạt - 2186400229

GVHD: TS. Bùi Danh Hường
Đại học Công nghệ Tp. HCM



HUTECH
Đại học Công nghệ Tp.HCM

Nội Dung

- 1 Tổng quan đề tài
- 2 Chuẩn bị dữ liệu
- 3 Khám phá dữ liệu
- 4 Phân cụm trước khi sử dụng khai thác mẫu thường xuyên
- 5 Phân cụm sau khi sử dụng khai thác mẫu thường xuyên
- 6 Kết luận

Tổng quan đề tài

Lý do chọn đề tài

- Tầm quan trọng của hiểu biết thị trường: Giúp đưa ra quyết định chiến lược hiệu quả.
- Phân tích phân cụm: Nhận diện nhóm cửa hàng có đặc điểm tương đồng.
- Ứng dụng thực tiễn:
 - Tối ưu hóa hoạt động kinh doanh.
 - Cải thiện dịch vụ khách hàng.
 - Nâng cao hiệu quả marketing.
- Ý nghĩa phát triển chiến lược:
 - Hỗ trợ doanh nghiệp nắm bắt xu hướng.
 - Phát triển chiến lược kinh doanh bền vững.

Mục tiêu đề tài

- Thu thập và xử lý dữ liệu.
- Phân cụm dữ liệu.
- Tối ưu hóa hiệu quả phân cụm.
- Phân tích kết quả phân cụm.
- Đề xuất chiến lược phù hợp.

Chuẩn bị dữ liệu

Thu thập và tiền xử lý dữ liệu

Thu thập dữ liệu:

- Dữ liệu thu thập từ sàn thương mại điện tử Tiki bằng phương pháp API Scraping.
- Dữ liệu ban đầu gồm: 73.300 mẫu chứa thông tin về các cửa hàng, thông tin về sản phẩm của cửa hàng và các đánh giá của khách hàng trên từng sản phẩm.
- Dữ liệu sau khi tiền xử lý dữ liệu.

Revenue	YearJoined	Followers	ChatResponse	RatingQuality	PositiveQuality
1,326,000	5	982	0	4.621877	0.787091
25,545,495	4	1500	0	4.631574	0.706230
3,148,294	7	479	0	4.350326	0.752689
6,572,000	6	565	1	4.560354	0.792613
529,000	6	137	0	4.648886	0.643643
2,261,000	5	955	0.66	4.545801	0.786455
816,900	8	181	0	4.168226	0.548946
966,000	8	3013	0.5	4.539589	0.770787

Table: Bảng dữ liệu hoàn chỉnh sau khi áp dụng định dạng.

Thu thập và tiền xử lý dữ liệu

Tiền xử lý dữ liệu cột "Revenue":

$$\text{Revenue}_{\text{store}} = \sum ((\text{QuantitySold}_{1\text{ month}} - \text{QuantitySold}_{\text{initial}}) \cdot \text{price}_{\text{product}})$$

- Trong đó:

- **Revenue_{store}**: Doanh thu ước tính của từng cửa hàng trong 1 tháng.
- **QuantitySold_{initial}**: Số lượng bán sau thu thập lần đầu.
- **QuantitySold_{1month}**: Số lượng bán sau thu thập lần đầu sau 1 tháng.
- **price_{product}**: Giá sản phẩm cửa hàng bán.

Thu thập và tiền xử lý dữ liệu

Tiền xử lý dữ liệu cột "RatingQuality":

- Là sự kết hợp với 2 biến **ShopRating** và **CounterRating**.
- Sử dụng phương pháp **Wilson score Interval** để đánh giá độ tin cậy của các cửa hàng để tạo ra thứ hạng khách quan hơn.
- Ưu tiên các cửa hàng có số lượng đánh giá lớn hơn và đáng tin cậy hơn.
- Ví dụ:
 - Một cửa hàng có **ShopRating** là 5.0 nhưng chỉ có 1 **CounterRating** thì độ tin cậy thấp.
 - Một cửa hàng khác có **ShopRating** là 4.5 nhưng có 500 **CounterRating** thì đáng tin cậy hơn.

Thu thập và tiền xử lý dữ liệu

Tiền xử lý dữ liệu cột "PositiveQuality":

- Ban đầu dữ liệu gồm các bình luận của khách hàng về sản phẩm.
- Sử dụng thư viện **underthesea** để:
 - Chuẩn hóa dữ liệu tiếng Việt (Normalize).
 - Phân đoạn câu (Tokenize).
 - Phân tích cảm xúc đánh giá của khách hàng (Sentiment).

==> **Positive, Negative, TotalFeedback**: Số lượng đánh giá tích cực, tiêu cực và tổng số lượng nhận xét của từng cửa hàng.

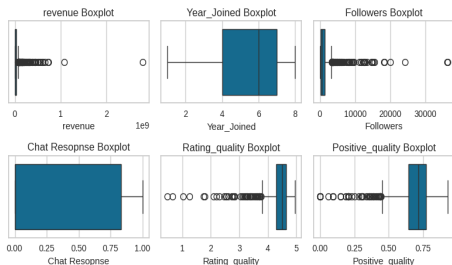
Thu thập và tiền xử lý dữ liệu

Tiền xử lý dữ liệu cột "PositiveQuality":

- Là sự kết hợp với 2 biến **Positive** và **TotalFeedback**.
- Sử dụng phương pháp **Wilson score Interval** để đánh giá độ tin cậy của các cửa hàng để tạo ra thứ hạng khách quan hơn.
- Ưu tiên các cửa hàng có số lượng nhận xét lớn hơn và đáng tin cậy hơn.
- Ví dụ:
 - Một cửa hàng có **Positive** là 20 trên 29 **TotalFeedback** thì độ tin cậy thấp.
 - Một cửa hàng khác có **Positive** là 20 nhưng có 24 **TotalFeedback** thì đáng tin cậy hơn.

Khám phá dữ liệu

Trực quan hóa dữ liệu



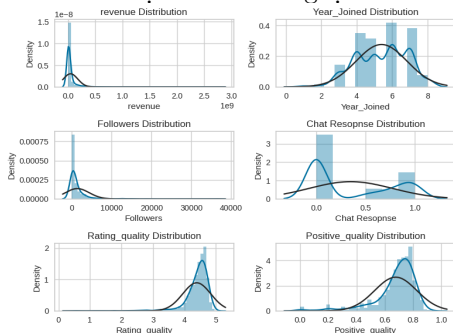
Ảnh 1: Biểu đồ BoxPlot.

Ảnh 2:

- Quan sát xu hướng phân phối của dữ liệu.
- Xác định độ lệch của dữ liệu.

Ảnh 1:

- Tóm tắt dữ liệu(interquantile, min, max).
- Phát hiện các điểm ngoại lai.



Ảnh 2: Biểu đồ phân phối.

Chuẩn hóa dữ liệu

Chuẩn hóa dữ liệu bằng ScalerStandard (Z-score): Đưa dữ liệu về trung bình ($=0$) và độ lệch chuẩn ($=1$).

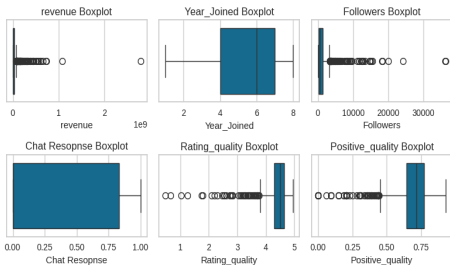
- **Đưa dữ liệu về thang đo chung:** Loại bỏ sự khác biệt về đơn vị đo lường.
- **Cải thiện hiệu suất mô hình:** Đặc biệt quan trọng với các thuật toán nhạy cảm với thang đo.

Revenue	YearJoined	Followers	ChatResponse	RatingQuality	PositiveQuality
-0.326840	-0.279443	-0.143533	-0.819518	0.517466	0.731572
-0.143226	-0.972848	0.031235	-0.819518	0.539159	0.189270
-0.260906	0.413962	1.358861	1.525984	0.663007	1.056228
-0.313024	1.107368	-0.313240	-0.819518	-0.090066	0.500853
-0.287069	0.413962	-0.284224	1.525984	0.379822	0.768611

Table: Bảng dữ liệu sau khi áp dụng StandardScaler

Xử lý Outliers

Xử lý Outliers bằng phương pháp Winsorization:



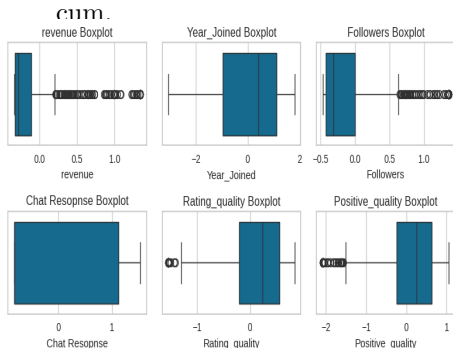
Ảnh 1: Trước khi áp dụng Winsorization.

Nhược điểm:

- Không giải quyết được mọi vấn đề ngoại lệ.
- Không phù hợp với dữ liệu ngoại lệ có ý nghĩa.

Ưu điểm:

- Giảm tác động của giá trị ngoại lệ.
- Bảo tồn dữ liệu.
- Cải thiện độ chính xác của các



Ảnh 2: Sau khi áp dụng Winsorization.

Xử lý Outliers

Xử lý Outliers bằng phương pháp Isolation Forest:

Isolation Forest?

- Cô lập dữ liệu trong không gian nhiều chiều.
- Phát hiện outliers dựa trên tính dễ bị cô lập của chúng.

Lợi ích:

- Cải thiện chất lượng cụm.
- Xử lý tốt dữ liệu không tuyến tính hoặc phân phối phức tạp.
- Hiệu quả với dữ liệu nhiều chiều.
- Giảm thời gian và chi phí tính toán cho phân cụm.

Visualization of Data and Outliers using ISOLATION FOREST




Figure: Isolation Forest.

DBSCAN

Kiểm tra và Xử lý Outliers bằng DBSCAN:

DBSCAN?

- Không yêu cầu phân phối dữ liệu cụ thể.
- Tự động phát hiện điểm mật độ thấp, xa cụm chính (gán nhãn -1).

Lợi ích:

- Xử lý tốt cụm phức tạp.
- Không phụ thuộc trung tâm cụm.
- Hiệu quả với dữ liệu nhiễu.


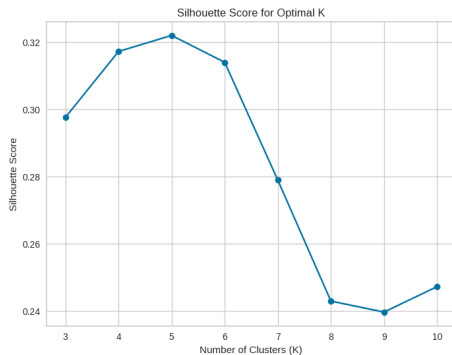


Figure: DBSCAN

Phân cụm trước khi sử dụng khai thác mẫu thường xuyên

Xác định số cụm tối ưu

Xác định số cụm tối ưu cho K-Means bằng Silhouette



Number of Clusters	Silhouette Score
3	0.273251
4	0.300402
5	0.329759
6	0.298026
7	0.281516
8	0.240029
9	0.251132
10	0.233334

Bảng x.x: Bảng chỉ số Silhouette


Figure: Điểm Silhouette từng cụm.

Đánh giá:

- Chỉ số Silhouette trung bình cho thấy số cụm tối ưu khi sử dụng K-Means là 5.

Xác định số cụm tối ưu

Xác định số cụm tối ưu bằng Silhouette cho Agglomerative



Number of Clusters	Silhouette Score
3	0.287882
4	0.307923
5	0.297408
6	0.268597
7	0.246244
8	0.210636
9	0.222362
10	0.216999

Bảng x.x: Bảng chỉ số Silhouette


Figure: Điểm Silhouette từng cụm.

Đánh giá:

- Chỉ số Silhouette trung bình cho thấy số cụm tối ưu khi sử dụng Agglomerative là 4.

Xác định số cụm tối ưu

Xác định số cụm tối ưu bằng Silhouette cho Gaussian Mixture Model



Number of Components	Silhouette Score
3	0.269414
4	0.313566
5	0.320873
6	0.287968
7	0.281033
8	0.202343
9	0.252042
10	0.234785

Bảng x.x: Bảng chỉ số Silhouette

Figure: Điểm Silhouette từng cụm.


Đánh giá:

- Chỉ số Silhouette trung bình cho thấy số cụm tối ưu khi sử dụng Gaussian Mixture Model là 5.


Phân cụm K-Means, Agglomerative, Gaussian Mixture Model

Thuật toán	Silhouette Score	Davies-Bouldin Index (DBI)	Calinski-Harabasz Index (CHI)
K-Means	0.65	1.25	500.1
Agglomerative	0.68	1.20	520.3
Gaussian Mixture Model (GMM)	0.62	1.30	480.5


Table: So sánh các thuật toán phân cụm dựa trên các chỉ số đánh giá.



K-Means (k=5)



Agglomerative (k=4)



GMM (k=5)

Phân cụm sau khi sử dụng khai thác mẫu thường xuyên

Áp dụng khai thác mẫu thường xuyên FP-Max

Rời rạc hóa dữ liệu K-Bins Discretizer:

- Sử dụng K-Means để rời rạc hóa dữ liệu về 3 phần: Low, Medium, High.
- ...

Áp dụng FP-Max

- Sử dụng Fp-Max để tạo ra các frequent itemset.
- ...

Tạo ra các đặc trưng dữ liệu mới từ frequent itemset:

- Sử dụng Fp-Max để tạo ra các frequent itemset.
- ...

Phân cụm K-Means




Figure: K-Means trước khi sử dụng FIM.




Figure: K-Means sau khi sử dụng FIM.

- Silhouette: 0.313 -> 0.4328
- Davies-Bouldin Index: 1.127 -> 1.08
- Calinski-Harabasz Index (CHI): 355.75 -> 462.050

Phân cụm Agglomerative



Figure: Agglomerative trước khi sử dụng FIM.



Figure: Agglomerative sau khi sử dụng FIM.

- Silhouette: 0.228 -> 0.549
- Davies-Bouldin Index: 1.224 -> 0.758
- Calinski-Harabasz Index (CHI): 297.206 -> 1657.65

Phân cụm GMM (Gaussian Mixture Model)




Figure: GMM trước khi sử dụng FIM.




Figure: GMM sau khi sử dụng FIM.

- Silhouette: 0.3132 -> 0.3504
- Davies-Bouldin Index: 1.107 -> 1.087
- Calinski-Harabasz Index (CHI): 399.912 -> 381.3246

Kết luận

Phân tích

Đề xuất